# EEG Causal Graphs for Three-Class Classification

## Slide 1: Titolo e Introduzione

Buongiorno alla commissione e a tutti i presenti. Sono Michele Arrigoni e, come parte del mio percorso nella Laurea Magistrale in Informatica all'Università degli Studi di Milano, vi presento il progetto "EEG Causal Graphs for Three-Class Classification". Il focus di questo lavoro è creare una baseline per classificare tre categorie cliniche a partire da registrazioni EEG in stato di riposo: soggetti sani di controllo (CN), pazienti con malattia di Alzheimer (AD) e pazienti con demenza frontotemporale (FTD).

## Slide 2: Rappresentazione a Grafo dei Dati

L'impianto metodologico prevede di trasformare ogni registrazione multicanale in un grafo omogeneo per ciascun soggetto. In questa struttura, i nodi corrispondono ai 19 canali dell'assetto EEG standard, gli attributi dei nodi descrivono l'attività spettrale e statistica locale, e gli archi orientati codificano la connettività diretta stimata tramite metodi avanzati per serie temporali. È fondamentale chiarire che utilizziamo il termine "causale" in un'accezione puramente statistica. Un arco indica che lo stato passato o strutturale di un canale aiuta a spiegarne un altro secondo le assunzioni del modello, ma non costituisce la prova di un percorso fisiologico diretto, poiché l'EEG da scalpo è fisiologicamente affetto da conduzione di volume e dalla presenza di sorgenti neurali latenti.

## Slide 3: I Dataset Analizzati

Per garantire il rigore dell'analisi, ho processato e confrontato due dataset distinti: 87 soggetti estratti da OpenNeuro e 85 soggetti da BrainLat. Una decisione architetturale cruciale è stata quella di analizzarli sempre separatamente, senza mai unire i 172 soggetti totali per la classificazione. I due dataset presentano infatti differenze sostanziali nella composizione demografica, nelle condizioni di acquisizione, nella geometria degli elettrodi e

nella durata delle registrazioni. Unire questi dati avrebbe comportato il grave rischio di far diventare l'identità del dataset un fattore di confondimento primario per il classificatore.

## Slide 4: Pipeline di Preprocessing

La pipeline di pulizia del segnale inizia con un filtraggio passa-banda tra 0.5 e 40 Hz e un filtro notch a 50 Hz, seguiti da un ricampionamento a 100 Hz, che fissa la frequenza di Nyquist a 50 Hz preservando tutte le bande cerebrali di interesse. Il segnale continuo viene quindi frammentato in epoche non sovrapposte di 5 secondi. Per evitare bias predittivi legati alla durata della registrazione, ho selezionato per ogni soggetto lo stesso numero di epoche valide all'interno del rispettivo dataset: 61 per OpenNeuro e 28 per BrainLat. Il controllo qualità elimina le epoche con ampiezze estreme superiori a 150 microvolt, e i dati vengono standardizzati tramite Z-score. Infine, per soddisfare i requisiti dell'inferenza autoregressiva, ogni canale viene sottoposto ai test di stazionarietà ADF e KPSS; in caso di fallimento, si applica una differenziazione temporale.

## Slide 5: Estrazione delle Feature dei Nodi

Passiamo alla descrizione dei nodi: ogni canale è rappresentato da un vettore di otto componenti. Tre sono puramente statistiche, ovvero media, deviazione standard e varianza, mentre le restanti cinque sono le potenze spettrali nelle bande delta, theta, alfa, beta e gamma, stimate con il metodo di Welch. Un dettaglio tecnico di vitale importanza è che queste potenze vengono estratte prima di applicare l'eventuale differenziazione per la stazionarietà. Questa accortezza permette di mantenere intatto il contenuto a bassa frequenza, in particolar modo la banda delta, che verrebbe altrimenti severamente alterata e distorta dall'effetto passa-alto introdotto dalla differenziazione.

## Slide 6: Stima della Connettività Diretta

Il nucleo computazionale del progetto è la stima degli archi, per la quale ho implementato e confrontato tre metodi, escludendo in tutti i casi le auto-connessioni:

- **Granger Causality:** valuta se i valori passati di un canale sorgente migliorino la previsione di un target, testando ordini autoregressivi da 1 a 4 (ovvero dai 10 ai 40 millisecondi) tramite test F e applicando un rigoroso controllo FDR per limitare i falsi positivi.
- **VARLINGAM:** un modello vettoriale autoregressivo che stima gli effetti strutturali lineari. Utilizza il criterio BIC per selezionare l'ordine ottimale e il pruning per sopprimere i coefficienti deboli, mediando infine i coefficienti ritardati in valore assoluto per produrre pesi non negativi.
- **PCMCI:** un algoritmo che opera in due fasi per scartare le connessioni spurie; prima seleziona un set di genitori candidati, e poi esegue test di indipendenza condizionata momentanea tramite il test ParCorr, imponendo soglie di significatività rigorose a 0.01.

I pesi ottenuti per le singole epoche vengono infine mediati per produrre un'unica matrice di adiacenza statica e riassuntiva per ogni soggetto.

## Slide 7: Esperimenti di Classificazione e Risultati

Nella fase finale, queste diverse varianti dei grafi sono state fornite a un compatto Multi-Layer Perceptron (MLP) per la classificazione a tre classi, addestrato e valutato indipendentemente all'interno di ciascun dataset.

- Su **OpenNeuro**, la rappresentazione a grafo generata da VARLINGAM ha ottenuto la metrica migliore, con una balanced accuracy sul test set di 0.605.
- Sul dataset **BrainLat**, le performance sono state nettamente superiori: i modelli basati sui grafi di Granger e VARLINGAM hanno pareggiato, raggiungendo entrambi la migliore balanced accuracy osservata, pari a 0.821.

## Slide 8: Conclusioni e Lavori Futuri

In conclusione, i risultati confermano la solidità e la validità dell'approccio basato su grafi causali per estrarre informazioni clinicamente discriminanti dalle serie temporali EEG. Tuttavia, è fondamentale riconoscere un limite metodologico dell'attuale sperimentazione: le valutazioni effettuate in "single-split" all'interno della medesima coorte non ci permettono di misurare l'effettiva capacità di generalizzazione cross-dataset del modello. Questa

validazione incrociata rappresenterà il naturale passo successivo e la sfida principale per i futuri sviluppi di questa ricerca.

Vi ringrazio per l'attenzione e resto a disposizione per rispondere a qualsiasi domanda o curiosità tecnica.