Correzioni e chiusura del progetto

Buongiorno Michele,

ho letto con attenzione il codice e il report. Il lavoro è impostato bene: la pipeline è ordinata e pertinente. Nel seguito ti segnalo le cose che vanno sistemate prima di fissare l'esame. In più, visto che si tratta di un esame congiuto sarebbe opportuno integrare quello che hai già fatto con 2 aspetti: training di un piccolissimo MLP per classificare AD, FTD e CN dal pre-processing di almeno uno dei metodi (Lingam, Granger e PCMCI).

1. Cose da sistemare

1.1 assicurati che la matrice di Granger non venga fuori tutta a zeri

In `granger_causality.py` , riga 51, chiami:

```
results = grangercausalitytests(pair_data, maxlag=max_diff, verbose=False)
```

Non vorrei sbagliarmi, ma il parametro `verbose` pare sia stato tolto da `statsmodels` nella versione 0.15 (quella che dichiari di usare nel tuo environment). Se giri con quella versione, la chiamata solleva un `TypeError` . Il punto è che tu hai avvolto tutto in un:

```
except Exception:
    continue
```

quindi l'errore dato dal verbose potrebbe riperquotersi nel far saltare completamente la parte granger (e la `A` resta la matrice di zeri con cui l'avevi inizializzata). Controlla questa cosa e assicurati di correggere o di smentire la mia osservazione.

Cosa potresti fare. Togli `verbose=False` , la funzione non lo accetta più:

```
results = grangercausalitytests(pair_data, maxlag=max_diff)
```

E, più in generale, non usare mai `except Exception: continue` senza almeno stampare cosa è successo.

1.2 Il controllo di qualità sulle epoche potrebbe non scartare nulla

In `preprocessing.py` :

```
def is_good_epoch(epoch, amp_treshold = 150.0):
    if np.max(np.abs(epoch)) > amp_treshold:
        return False
```

L'idea è giusta (150 µV è una soglia ragionevole per un artefatto), ma MNE di solito restituisce i dati in **Volt**, non in microvolt. Assicurati di avere dati nella stessa unità di misura della soglia presente nel controllo che prevedi di fare.

Cosa potresti fare. Una riga:

```
def is_good_epoch(epoch, amp_threshold=150e-6):   # 150 µV espressi in Volt
```

Poi rilancia e guarda quante epoche vengono scartate. Se non ne scarta nessuna, la soglia va alzata; se ne scarta metà, va abbassata.

1.3 L'ottava feature è identica su tutti i 19 canali

Ho caricato il tuo `minimal_output` e ho controllato la colonna 7 di `X.npy` (`stationarity_fraction`). Ho trovato **lo stesso identico valore su tutti i 19 canali** di uno stesso soggetto. Non è una feature del nodo: è un numero del soggetto, ripetuto 19 volte.

Pare che il motivo stia in `stationary_feature_for_channel` . Dentro il ciclo tu recuperi i controlli del canale:

```
checks = epoch_report["channels"].get(ch_name, [])
if len(checks) == 0: continue
total += 1
if epoch_report["diffed"]:      # <-- questo è il flag dell'EPOCA, non del canale
    diffs_required += 1
```

`epoch_report["diffed"]` è `True` se **l'epoca** è stata differenziata, e la differenziazione in `make_epoch_stationary` viene applicata a **tutti i canali insieme** (`np.diff(current, axis=1)`). Quindi la risposta è la stessa per tutti.

Cosa fare. Scegli tu:

- togli la feature (resti con 7 feature, che è anche il numero che usa ECoGNet);
- oppure, registra per ciascun canale se **quel canale** risultava non stazionario al momento in cui è stata decisa la differenziazione, e usa quella frazione. I dati per farlo li hai già in `report["channels"][ch]` , ti serve il campo `adf_ok` / `kpss_ok` dell'ultima iterazione.

1.4 Stai differenziando l'81 % delle epoche, e poi calcoli lo spettro su quelle

La `stationarity_fraction` media nel tuo output è **0.81**: quattro epoche su cinque vengono differenziate, alcune due volte. Differenziare una serie temporale (`x[t] − x[t−1]`) è, in termini di frequenza, un filtro passa-alto: attenua le componenti lente e amplifica quelle veloci. Se poi calcoli la potenza della banda di frequenze 'delta' sul segnale differenziato quella potenza risulta corrotta e spesso nulla (dato che è stata filtrata via dal passa alto).

Perché il codice tende a differenziare così spesso? Perché la regola che hai messo per provare la stazionarietà richiede che **entrambi** i test (ADF e KPSS) diano esito positivo, e KPSS su 250 campioni di un segnale EEG già filtrato tende a rifiutare quasi sempre. La regola pare sia troppo severa.

Cosa fare. Tre possibilità, in ordine di sforzo:

1. calcola le feature spettrali **prima** della differenziazione;
2. rilassa la regola: usa solo ADF, oppure differenzia solo se **entrambi** i test dicono "non stazionario" invece che se almeno uno lo dice;
3. abbassa `max_diffs` a 1.

1.5 Simmetrizzare l'adiacenza cancella una cosa importante

In `prepare_adjacency_for_hgcn` fai `A = 0.5 * (A + A.T)` e nel report scrivi una cosa tipo ("The trade-off is the loss of direction") Qui la questione richiede capire bene la differenza fra **connettività funzionale** e **connettività effettiva**. Granger, LiNGAM e PCMCI servono per la connettività effettiva, se simmetrizzi, tutto il lavoro di Granger, LiNGAM e PCMCI produce alla fine lo stesso tipo di oggetto che avresti ottenuto con una banale correlazione (connettività funzionale).

Cosa potresti fare. salva **entrambe** le versioni, `A.npy` (simmetrica, come adesso) e `A_directed.npy` (senza simmetrizzare). Per le figure di connettività (cosa che ti chiedo di fare tra un attimo) ti serve quella direzionata, altrimenti non puoi disegnare le frecce.

1.6 La fusione non va bene

```
A = 0.50·Ã_granger + 0.25·Ã_lingam + 0.25·Ã_pcmci
```

Le tre matrici misurano cose diverse, non solo su scale diverse:

- Granger ti dà una **frazione di lag significativi**, cioè un numero fra 0 e 1 che conta quante volte un test ha rifiutato l'ipotesi nulla;
- DirectLiNGAM ti dà un **coefficiente strutturale**, cioè l'ampiezza di un effetto;
- PCMCI ti dà una **correlazione parziale**, cioè una dimensione d'effetto condizionata.

Dividere per il massimo (come fai) rende comparabili le *scale*, ma non i *significati*.

Cosa fare. Ti chiedo di:

- tenere le tre matrici separate come oggetto principale (le hai già: `A_granger.npy`, `A_lingam.npy`, `A_pcmci.npy`) sia in versione undirected che directed;
- nel classificatore (vedi to-do) prova almeno ad usarne una, ma non la loro fusione.

1.7 DirectLiNGAM non è il modello giusto per una serie temporale

Per le serie temporali la libreria `lingam` giusta è `VARLiNGAM`, che stima un modello:

```
x(t) = B₀·x(t) + B₁·x(t−1) + ... + B_p·x(t−p) + e(t)
```

cioè ti restituisce sia la parte istantanea `B₀` sia gli effetti ritardati `B₁…B_p`.

Cosa fare. Se hai tempo, sostituisci con:

```
model = lingam.VARLiNGAM(lags=maxlag, criterion=None, prune=False)
model.fit(epoch.T)
B = model.adjacency_matrices_      # lista [B0, B1, ..., Bp]
```

Se non hai tempo, dichiaralo come limite nel report: stai stimando la sola componente istantanea.

1.8 Attenzione alla frequenza di campionamento

Mi sembra che tu abbia impostato `high_freq = 24.0` e `target_fs = 50`, quini la frequenza di Nyquist è 25 Hz. Praticamente tagli completamente dal segnale le bande beta e gamma. Capisco possa essre dovuto a motivi di risorse computazionali, se non hai modo di alzare la frequenza di campionamento aggiungi questa come limitazione nel report.

4. To-do per chiudere e fissare l'esame

Oltre alla correzione di quello che ho riportato sopra (vedi quanto tempo hai e quello che riesci a fare), ti chiedo di:

Creare figure di connettività

Per ogni **classe** (CN, AD, FTD) e per ogni **metodo** (Granger, LiNGAM, PCMCI), una figura della rete di connettività, sul modello di quelle in ECoGNet (paper che ti avevo mandato e che puoi recuperare dalla traccia del progetto).

Come costruirla:

- parti dalle matrici **direzionate**, non da quella simmetrizzata;
- media le matrici dei soggetti della stessa classe (media, non somma, perché i gruppi hanno numerosità diversa: 36 AD, 29 CN, 23 FTD);
- disegna solo i collegamenti più forti, per esempio sopra l'80° percentile calcolato **una volta sola su tutte e tre le classi insieme** — questo è importante: se calcoli una soglia diversa per ogni classe, tutte le figure avranno lo stesso numero di archi e non vedrai la differenza che ti interessa;
- disponi i 19 elettrodi su un cerchio, mantenendo lo stesso ordine in tutte le figure;
- spessore dell'arco proporzionale alla forza, colore dell'arco uguale al colore dell'elettrodo **sorgente** (così si legge la direzione), e una freccia se riesci.

Il risultato atteso, se tutto è a posto, è quello che riporta ECoGNet: CN con più collegamenti, FTD con meno (soprattutto frontali), AD con ancora meno.

Aggiungi anche una figura riassuntiva: per ogni classe e ogni metodo, il **numero di archi sopra soglia** e la **forza media**, in un istogramma. È il modo più diretto di mostrare quantitativamente quello che le figure mostrano qualitativamente.

Classificatore a tre classi

Se riesci (in base ala capacità del tuo computer) e c'è tempo, allena un classificatore semplice: regressione logistica oppure un MLP con un solo hidden layer.

Cosa dai in ingresso. feature nodali (19 × n_feature) + adiacenza 171 (triangolo superiore) o 342 (matrice direzionata senza diagonale) di uno dei metodi di pre-processing (Lingam o Granger o PCMCI).

Come valuti. Questo è il punto su cui si sbaglia più spesso:

- il campione è il **soggetto**, non l'epoca. Tu hai già un grafo per soggetto. Usa un 70/10/20 train-test-validation split.
- **normalizza le feature usando solo il training fold**: calcoli media e deviazione standard sui soggetti di training e le applichi al test.
- la metrica è la **balanced accuracy**, non l'accuracy. Le classi sono sbilanciate.
- riporta anche la **matrice di confusione**.
- usa `class_weight="balanced"` nel classificatore, così pesa di più le classi meno numerose.

Cosa aspettarti. Ti dico in anticipo un risultato, così non ti spaventi: ho provato io un classificatore semplice sul tuo `minimal_output` così com'è, e sulla sola adiacenza fusa la balanced accuracy sta intorno a **0.41-0.43**, cioè al livello del caso. Sulle feature nodali sale a **0.51-0.56**. Se dopo le correzioni i numeri migliorano, è un risultato. Se non migliorano, non preoccuparti.

Aggiornare il report

Aggiungi una sezione con le figure, una tabella con i risultati della classificazione.

Se qualcosa non è chiaro, non esitare a scrivimi.